



Création et utilisation de la base de données

Humbert Claudie



Contexte du projet

DATA IMMO 2020

- Projet DATA IMMO permettant la création d'un modèle de prévision pour les biens immobiliers.
- Essai sur l'année 2020 pour une extension du projet aux années futures.



La stratégie de sauvegarde et la conformité RGPD

- Stratégie de sauvegarde
 - Plusieurs sauvegardes sur environnement différents
 - Conservation de versions antérieures
- Respect du RGPD
 - Respect de la finalité du traitement
 - Conserver seulement les données nécessaires au traitement
 - Suppression des données à caractères personnelles

Les données initiales

- Extrait des demandes de valeurs foncières (DVF): Données en open data, contenant les valeurs des biens, la date de leurs transactions, leurs localisations et descriptifs
- Recensements de la population par commune (Données de l'INSEE)
- Données des régions avec référentiel géographique français, communes, unités urbaines, aires urbaines, départements et académies

L'extrait du dictionnaire des données

DICTIONNAIRE DES DONNÉES - Valeurs foncières

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_bien	ID du bien dans la base de données	INTEGER	NC	Calculer	Ne doit pas être nul	Formule permettant de créer une ID propre à chaque bien =SI(NB.SI(\$P\$2:P2; P2)=1; LIGNE()-1; INDEX(\$A\$1:A1; EQUIV(P2; \$P\$1:P1; 0)))
id_commune	ID de la commune dans la base de données	VARCHAR	6	Concaténer	Ne doit pas être nul	Concaténation des code département avec le code commune
id_vente	ID de la vente dans la base de données	INTEGER	NC	Calculer	Ne doit pas être nul	Incrémementation
type_local	Type de bien (maison ou appartement)	ENUM	15	Elémentaire	Ne doit pas être nul	
surface_carrez	Surface du bien selon la loi Carrez	FLOAT	NC	Elémentaire	Ne doit pas être nul	
surface_reelle	Surface du bien selon la mesure au sol	INTEGER	NC	Elémentaire	Ne doit pas être nul	
nombre_pieces	Nombre de pièces du bien	INTEGER	NC	Elémentaire	Ne doit pas être nul	
date_vente	Date de signature de l'acte de vente du bien	DATE	NC	Elémentaire	Ne doit pas être nul, format (aaaa/mm/jj)	
valeur	Valeur du bien	INTEGER	NC	Elémentaire	Arrondi	


DICTIONNAIRE DES DONNÉES - Référentiel géographique

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_commune	ID de la commune dans la base de données	VARCHAR	6	Elémentaire	Ne doit pas être nul	
nom_commune	NOM de la commune dans la base de données	VARCHAR	40	Elémentaire	Ne doit pas être nul	
dep_code	CODE du département de la commune dans la base de données	VARCHAR	3	Concaténer	Ne doit pas être nul	
dep_nom	NOM du département de la commune dans la base de données	VARCHAR	25	Elémentaire	Ne doit pas être nul	
reg_code	CODE de la region de la commune dans la base de données	INTEGER		Elémentaire	Ne doit pas être nul	
reg_nom	NOM de la region de la commune dans la base de données	VARCHAR	30	Elémentaire	Ne doit pas être nul	

DICTIONNAIRE DES DONNÉES - Données communes

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_commune	ID de la commune dans la base de données	VARCHAR	6	Elémentaire	Ne doit pas être nul	Concaténation de la colonnes CODDEP avec CODCOM
population	Population total de la commune	INTEGER	NC	Elémentaire		

Le schéma relationnel normalisé



La base de données avec les tables créées et les données chargées

Table : region

Column Name	Datatype	PK	NN
reg_nom	VARCHAR(30)	☐	☒
reg_code	INT	☒	☒

reg_nom	reg_code
Collectivités d'outre-mer	0
Guadeloupe	1
Martinique	2
Guyane	3
La Réunion	4

Table : bien

Column Name	Datatype	PK	NN
id_bien	INT	☒	☒
id_commune	VARCHAR(6)	☐	☒
surface_carrez	FLOAT	☐	☒
type_local	VARCHAR(15)	☐	☒
surface_relle	INT	☐	☒
nombre_pieces	INT	☐	☒

id_bien	id_commune	surface_carrez	type_local	surface_relle	nombre_pieces
1	01103	48.22	Appartement	48	3
2	06004	39.11	Appartement	40	1
3	06088	80.25	Appartement	82	3
4	06123	27.51	Appartement	27	1
5	13005	47.33	Appartement	47	2
6	13028	25.31	Appartement	24	1
7	13208	70.84	Appartement	70	3

Table : commune

Column Name	Datatype	PK	NN
id_commune	VARCHAR(6)	☒	☒
dep_code	VARCHAR(3)	☐	☒
nom_commune	VARCHAR(40)	☐	☒
dep_nom	VARCHAR(25)	☐	☒
reg_code	INT	☐	☒
population	INT	☐	☐

id_commune	dep_code	nom_commune	dep_nom	reg_code	population
01001	01	L ABERGEMENT CLEMENCIAT	Ain	84	798
01002	01	L ABERGEMENT DE VAREY	Ain	84	257
01004	01	AMBERIEU EN BUGEY	Ain	84	14514
01005	01	AMBERIEUX EN DOMBES	Ain	84	1776
01006	01	AMBLEON	Ain	84	118

Table : vente

Column Name	Datatype	PK	NN
id_vente	INT	☒	☒
id_bien	INT	☐	☒
date_vente	DATETIME	☐	☒
valeur	INT	☐	☐

id_vente	id_bien	date_vente	valeur
0	1	2020-01-02 00:00:00	165000
1	2	2020-01-02 00:00:00	355680
2	3	2020-01-02 00:00:00	229500
3	4	2020-01-02 00:00:00	125000

Les requêtes ou screenshot qui permettent de démontrer le bon chargement des données

5 • `SELECT COUNT(*) FROM region;`

Result Grid	Filter Rows:
COUNT(*)	
▶ 19	

5 • `SELECT COUNT(*) FROM commune;`

Result Grid	Filter Rows:
COUNT(*)	
▶ 34991	

5 • `SELECT COUNT(*) FROM bien;`

Result Grid	Filter Rows:
COUNT(*)	
▶ 30770	

5 • `SELECT COUNT(*) FROM vente;`

Result Grid	Filter Rows:
COUNT(*)	
▶ 34169	



Requêtes SQL et résultats

Requête 1

Nombre total d'appartements vendus au 1er semestre 2020

```
1 • SELECT COUNT(distinct v.id_bien) AS total_appartements_vendus_1er_semestre
2 FROM vente v
3 JOIN bien ON v.id_bien = bien.id_bien
4 WHERE bien.type_local = 'Appartement'
5 AND v.date_vente BETWEEN '2020-01-01' AND '2020-06-30';
6
```

Result Grid   Filter Rows: Export:  Wrap Cell Content: 	
	total_appartements_vendus_1er_semestre
▶	28094

Requête 2

Le nombre de ventes d'appartement par région pour le 1er semestre 2020

```
1 • SELECT r.reg_nom AS region,  
2 COUNT(distinct v.id_vente) AS nombre_ventes_appartements_1er_semestre  
3 FROM vente v  
4 JOIN bien b ON b.id_bien = v.id_bien  
5 JOIN commune c ON c.id_commune = b.id_commune  
6 JOIN region r ON r.reg_code = c.reg_code  
7 WHERE b.type_local = 'Appartement'  
8 AND v.date_vente BETWEEN '2020-01-01' AND '2020-06-30'  
9 GROUP BY region  
10 ORDER BY nombre_ventes_appartements_1er_semestre DESC;
```

Result Grid		Filter Rows:	Export:	Wrap Cell Content:
region	nombre_ventes_appartements_1er_semestre			
Ile-de-France	13995			
Provence-Alpes-Côte d'Azur	3649			
Auvergne-Rhône-Alpes	3253			
Nouvelle-Aquitaine	1932			
Occitanie	1641			
Pays de la Loire	1357			
Hauts-de-France	1251			
Bretagne	985			
Grand Est	984			
Normandie	861			
Centre-Val de Loire	697			
Bourgogne-Franche-Comté	376			
Corse	225			
Martinique	94			
La Réunion	44			
Guyane	34			
Guadeloupe	2			

Requête 3

Proportion des ventes d'appartements par le nombre de pièces

```
2  #3 Proportion des ventes d'appartements par le nombre de pièces
3  • SELECT b.nombre_pieces,
4     COUNT(*) AS nb_ventes,
5     ROUND(COUNT(*) * 100.0 / SUM(COUNT(*) OVER (), 2) AS proportion_pourcentage
6 FROM vente v
7 JOIN bien b ON v.id_bien = b.id_bien
8 WHERE b.type_local = 'Appartement'
9 GROUP BY b.nombre_pieces
10 ORDER BY b.nombre_pieces;
11
```

Result Grid			Filter Rows:	Export:	Wrap Cell Content:
	nombre_pieces	nb_ventes	proportion_pourcentage		
0		28	0.09		
1		6719	21.41		
2		9796	31.22		
3		9001	28.68		
4		4428	14.11		
5		1115	3.55		
6		210	0.67		
7		54	0.17		
8		18	0.06		
9		8	0.03		
10		2	0.01		
11		1	0.00		

Requête 3 bis

Proportion des ventes d'appartements par le nombre de pièces
(médiane des valeurs)

```
WITH ventes_appartements AS (  
    SELECT  
        b.nombre_pieces,  
        v.valeur,  
        ROW_NUMBER() OVER (PARTITION BY b.nombre_pieces ORDER BY v.valeur) AS rn_asc,  
        COUNT(*) OVER (PARTITION BY b.nombre_pieces) AS total  
    FROM vente v  
    JOIN bien b ON v.id_bien = b.id_bien  
    WHERE b.type_local = 'Appartement'  
),  
mediane_calc AS (  
    SELECT  
        nombre_pieces,  
        valeur,  
        total,  
        rn_asc,  
        total / 2.0 AS milieu  
    FROM ventes_appartements  
)  
SELECT nombre_pieces,  
ROUND(AVG(valeur), 2) AS mediane_valeur  
FROM mediane_calc  
WHERE rn_asc IN (FLOOR(milieu), CEIL(milieu))  
GROUP BY nombre_pieces  
ORDER BY nombre_pieces;
```

Result Grid		Filter Rows:
	nombre_pieces	mediane_valeur
▶	0	91000.00
	1	110000.00
	2	149985.00
	3	190000.00
	4	215000.00
	5	260169.50
	6	552000.00
	7	1516000.00
	8	2950000.00
	9	599000.00
	10	242000.00
	11	139000.00

Requête 4

Liste des 10 départements où le prix du mètre carré est le plus élevé

```
1  #4 Liste des 10 départements où le prix du mètre carré est le plus élevé
2  • SELECT c.dep_nom AS departements,
3     round(avg(v.valeur / b.surface_carrez),2) AS prix_au_m2
4  FROM vente v
5  JOIN bien b ON v.id_bien=b.id_bien
6  JOIN commune c ON b.id_commune = c.id_commune
7  WHERE v.valeur IS NOT NULL
8  AND b.surface_carrez IS NOT NULL
9  AND b.surface_carrez > 0
10 GROUP BY departements
11 ORDER BY prix_au_m2 DESC
12 LIMIT 10;
```

Result Grid		Filter Rows:	Export:	Wrap Cell Content:	Fetch rows:
departements	prix_au_m2				
Paris	12322.67				
Hauts-de-Seine	7317.38				
Val-de-Marne	5324.85				
Alpes-Maritimes	4789.23				
Haute-Savoie	4678.98				
Seine-Saint-Denis	4341.91				
Yvelines	4331.95				
Corse-du-Sud	4102.53				
Rhône	4072.98				
Gironde	3838.98				

Requête 5

Prix moyen du mètre carré d'une maison en île-de-France

```
1  #5 Prix moyen du mètre carré d'une maison en ile-de-France
2  • SELECT
3  ROUND(AVG((CAST(v.valeur AS FLOAT)/b.surface_carrez)), 0) AS prix_au_m2_en_Ile_de_France
4  FROM vente v
5  JOIN bien b ON v.id_bien = b.id_bien
6  JOIN commune c ON b.id_commune = c.id_commune
7  JOIN region r ON c.reg_code = r.reg_code
8  WHERE b.type_local = 'Maison'
9  AND r.reg_nom = 'Ile-de-France'
10 AND b.surface_carrez > 0
11 AND v.valeur IS NOT NULL;
12
```

result Grid	Filter Rows:	Export:	Wrap Cell Content:
prix_au_m2_en_Ile_de_France			
3768			

Requête 6

Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés

```
1  #6 Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés
2  • SELECT
3    b.id_bien,
4    v.valeur as valeur_du_bien,
5    b.surface_carrez as surface_en_m2,
6    r.reg_nom AS region
7  FROM vente v
8  JOIN bien b ON v.id_bien = b.id_bien
9  JOIN commune c ON b.id_commune = c.id_commune
10 JOIN region r ON c.reg_code = r.reg_code
11 WHERE b.type_local = 'Appartement'
12 AND v.valeur IS NOT NULL
13 AND v.valeur > 0
14 AND b.surface_carrez > 0
15 ORDER BY v.valeur DESC
16 LIMIT 10;
17
18
```

Result Grid			
Filter Rows:			
Export: 			
Wrap Cell Content: ☐			
Fetch rows: 			
id_bien	valeur_du_bien	surface_en_m2	region
30603	9000000	9.1	Ile-de-France
5261	8600000	64	Ile-de-France
3625	8577713	20.55	Ile-de-France
7602	7620000	42.77	Ile-de-France
9988	7600000	253.3	Ile-de-France
17823	7535000	139.9	Ile-de-France
410	7420000	360.95	Ile-de-France
16357	7200000	595	Ile-de-France
1924	7050000	122.56	Ile-de-France
19161	6600000	79.38	Ile-de-France

Requête 7

Taux d'évolution du nombre de ventes entre le premier et e second trimestre de 2020

```
1  #7 Taux d'évolution du nombre de ventes entre le premier et e second trimestre de 2020
2  • SELECT
3      ventes_t1.nb_ventes AS ventes_T1_2020,
4      ventes_t2.nb_ventes AS ventes_T2_2020,
5      ROUND((ventes_t2.nb_ventes - ventes_t1.nb_ventes) * 100.0 / ventes_t1.nb_ventes,2) AS taux_evolution_pourcentage
6  FROM (SELECT COUNT(*) AS nb_ventes
7        FROM vente
8        WHERE date_vente BETWEEN '2020-01-01' AND '2020-03-31') AS ventes_t1,
9  (
10     SELECT COUNT(*) AS nb_ventes
11     FROM vente
12     WHERE date_vente BETWEEN '2020-04-01' AND '2020-06-30') AS ventes_t2;
```

Result Grid Filter Rows: Export: Wrap Cell Content:			
ventes_T1_2020	ventes_T2_2020	taux_evolution_pourcentage	
16776	17393	3.68	

Requête 8

Le classement des régions par rapport au prix du mètre carré des appartements de plus de 4 pièces

```
SELECT r.reg_nom AS region,  
ROUND(AVG(v.valeur / b.surface_carrez), 0) AS prix_m2_moyen  
FROM vente v  
JOIN bien b ON v.id_bien = b.id_bien  
JOIN commune c ON b.id_commune = c.id_commune  
JOIN region r ON c.reg_code = r.reg_code  
WHERE b.type_local = 'Appartement'  
AND b.surface_carrez > 0  
AND b.nombre_pieces > 4  
AND v.valeur IS NOT NULL  
GROUP BY r.reg_nom  
ORDER BY prix_m2_moyen DESC;
```

Result Grid		Filter Rows:
region	prix_m2_moyen	
Ile-de-France	8444	
La Réunion	3642	
Provence-Alpes-Côte d'Azur	3368	
Corse	3105	
Auvergne-Rhône-Alpes	2870	
Nouvelle-Aquitaine	2409	
Pays de la Loire	2316	
Bretagne	2316	
Hauts-de-France	2299	
Occitanie	2066	
Normandie	1966	
Grand Est	1555	
Centre-Val de Loire	1422	
Bourgogne-Franche-Comté	1262	
Martinique	573	

Requête 9

Liste des communes ayant eu au moins 50 ventes au 1er trimestre

```
1  #9 Liste des communes ayant eu au moins 50 ventes au 1er trimestre
2  • SELECT c.nom_commune, COUNT(*) AS nb_ventes
3  FROM vente v
4  JOIN bien b ON v.id_bien = b.id_bien
5  JOIN commune c ON b.id_commune = c.id_commune
6  WHERE v.date_vente BETWEEN '2020-01-01' AND '2020-03-31'
7  GROUP BY c.nom_commune
8  HAVING COUNT(*) >= 50
9  ORDER BY nb_ventes DESC;
```

nom_commune	nb_ventes
PARIS 17	228
PARIS 15	215
PARIS 18	209
NICE	173
PARIS 11	169
PARIS 16	165
BORDEAUX	157
PARIS 14	146
PARIS 20	127
NANTES	119
PARIS 19	116
PARIS 12	110
PARIS 10	109
GRENOBLE	106
PARIS 9	106
BOULOGNE BILLANCOURT	99
PARIS 13	94
PARIS 7	87
PARIS 6	86
ASNIERES SUR SEINE	81
MARSEILLE 8	81
COURBEVOIE	80
PARIS 5	79
PARIS 3	79

nom_commune	nb_ventes
TOULOUSE	78
ANTIBES	77
MARSEILLE 4	72
MARSEILLE 1	71
RUEIL MALMAISON	68
VINCENNES	68
LILLE	67
MARSEILLE 9	66
MONTREUIL	65
ANGERS	64
NIMES	63
LA CIOTAT	62
SETE	62
PARIS 8	62
PARIS 2	61
RENNES	61
PARIS 4	60
TOULON	59
LEVALLOIS PERRET	59
ST MAUR DES FOSSES	56
VERSAILLES	54
AJACCIO	54
PUTEAUX	53
ISSY LES MOULINEAUX	50

Requête 10

Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces

```
1  #10 Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces
2  • WITH prix_par_type AS (SELECT b.nombre_pieces,
3    ROUND(AVG(v.valeur / b.surface_carrez), 0) AS prix_m2
4    FROM vente v
5    JOIN bien b ON v.id_bien = b.id_bien
6    WHERE b.type_local = 'Appartement'
7    AND v.valeur IS NOT NULL
8    AND b.nombre_pieces IN (2, 3)
9    GROUP BY b.nombre_pieces)
10 SELECT
11   MAX(CASE WHEN nombre_pieces = 2 THEN prix_m2 END) AS prix_m2_2p,
12   MAX(CASE WHEN nombre_pieces = 3 THEN prix_m2 END) AS prix_m2_3p,
13   ROUND(
14     ABS(
15       (MAX(CASE WHEN nombre_pieces = 3 THEN prix_m2 END) - MAX(CASE WHEN nombre_pieces = 2 THEN prix_m2 END))
16       / MAX(CASE WHEN nombre_pieces = 2 THEN prix_m2 END) * 100),
17     2
18   ) AS difference_pourcentage
19 FROM prix_par_type;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content: I

	prix_m2_2p	prix_m2_3p	difference_pourcentage
▶	4987	4249	14.8

Requête 11

Titre requête

```
1  #11 Les moyennes de valeurs foncières pour le top 3 des communes des départements 6,13,33,59 et 69
2  WITH moyenne_par_commune AS (
3      SELECT
4          c.dep_code          AS departement,
5          c.nom_commune,
6          AVG(v.valeur)      AS moyenne_valeur
7      FROM vente v
8      JOIN bien b ON v.id_bien = b.id_bien
9      JOIN commune c ON b.id_commune = c.id_commune
10     WHERE c.dep_code IN ('06','13','33','59','69')
11           AND v.valeur IS NOT NULL
12     GROUP BY c.dep_code, c.nom_commune
13 ),
14 classement AS (
15     SELECT
16         departement,
17         nom_commune,
18         moyenne_valeur,
19         RANK() OVER (PARTITION BY departement ORDER BY moyenne_valeur DESC) AS rang
20     FROM moyenne_par_commune
21 )
22 SELECT
23     departement,
24     nom_commune,
25     ROUND(moyenne_valeur, 1) AS prix_moyen
26 FROM classement
27 WHERE rang <= 3
28 ORDER BY departement, rang, nom_commune;
--
```

	departement	nom_commune	prix_moyen
►	06	ST JEAN CAP FERRAT	968750.0
	06	EZE	655000.0
	06	MOUANS SARTOUX	476898.1
	13	GIGNAC LA NERTHE	330000.0
	13	ST SAVOURNIN	314425.0
	13	CASSIS	313416.9
	33	LEGE CAP FERRET	549500.6
	33	VAYRES	335000.0
	33	ARCACHON	307435.9
	59	BERSEE	433202.0
	59	CYSOING	408550.0
	59	HALLUIN	322250.0
	69	VILLE SUR JARNIOUX	485300.0
	69	LYON 2	455217.3
	69	LYON 6	426968.3

Requête 12

Les 20 communes avec le plus de transactions pour 1000 habitants
pour les communes qui dépassent les 10 000 habitants

```
SELECT c.nom_commune,  
COUNT(*) AS nb_ventes,  
ROUND(COUNT(*) * 1000.0 / c.population, 2) AS ventes_pour_1000_habitants,  
ROUND(AVG(b.surface_carrez),0) AS surface_carrez_moyenne,  
ROUND(AVG(v.valeur),0) AS valeur_moyenne  
FROM vente v  
JOIN bien b ON v.id_bien = b.id_bien  
JOIN commune c ON b.id_commune = c.id_commune  
WHERE c.population > 10000  
AND b.surface_carrez IS NOT NULL  
AND b.surface_carrez > 0  
AND v.valeur IS NOT NULL  
GROUP BY c.nom_commune, c.population  
ORDER BY ventes_pour_1000_habitants DESC  
LIMIT 20;
```

nom_commune	nb_ventes	ventes_pour_1000_habitants	surface_carrez_moyenne	valeur_moyenne
PARIS 2	127	5.84	42	521065
PARIS 1	79	4.92	54	1000675
PARIS 3	161	4.69	48	655954
ARCACHON	55	4.62	50	307436
LA BAULE	77	4.58	50	264745
PARIS 4	120	4.08	47	645485
ROQUEBRUNE CAP MARTIN	52	3.99	47	274173
PARIS 8	139	3.83	75	1010536
SANARY SUR MER	60	3.50	49	268489
PARIS 9	208	3.43	51	583177
LA LONDE LES MAURES	37	3.43	36	151213
PARIS 6	139	3.38	59	1005956
ST CYR SUR MER	38	3.24	53	256894
CHANTILLY	35	3.13	61	238481
ST MANDE	69	3.06	55	494061
PORNICHET	35	3.06	43	204127
PARIS 10	264	3.04	49	532282
MENTON	91	2.94	45	208585
ST HILAIRE DE RIEZ	33	2.87	36	85265
VINCENNES	141	2.81	50	433108



Merci !