

Rétrospective socio- démographique du parcours

Data Analyst

2022-2025



Choix des indicateurs :



- **Répartition par sexe**

Comprendre la parité parmi les étudiants entre OpenClassroom et lors d'une formation plus classique

- **Répartition par année**

Permet de visualiser le nombre d'inscriptions dans le temps

- **Répartition par régions**

Met en évidence les disparités territoriales



Méthodologie :

Collecte des données :

- **Données OpenClassroom** fournies par Marie-Neige format CSV
- **Données des effectifs étudiants sur le territoire national** fournies par data.gouv.fr format CSV :
 - « Effectifs d'étudiants inscrits dans les établissements et les formations de l'enseignement supérieur - détail par établissements »



Méthodologie :

Nettoyage :

(Staging)

Données OpenClassroom

- Unification des USER_ID
 - Contrôle d'unicité des USER_ID
- Remplacement des vides dans la colonne « Genre » par le terme « unknown »
- Mettre en minuscules le nom des régions pour s'assurer une conformité avec l'autre fichier de données

Données OpenClassroom

- Renommer le terme « féminin » en « F » et « masculin » en « M »
- Mettre en minuscule le nom des régions pour s'assurer une conformité avec l'autre fichier de données
- Mettre les régions « Guadeloupe », « Martinique », « Guyane », « la Réunion », « Mayotte » dans le terme « drom » conformément au fichier OpenClassroom



Méthodologie :

Modélisation avec DBT :

(Intermediate)

- Filtre sur le fichier étude classique pour n'obtenir que les regroupements de formation aboutissant à un métier de data analyste
- Filtre pour le fichier d'étude classique sur les années de rentrée pour n'avoir que les rentrées après 2022
- Renommer les colonnes pour avoir une conformité sur les 2 fichiers
- Calcul du nombre d'étudiants total par année de rentrée, régions et genre
- Ordonner les fichiers avec les colonnes suivant l'ordre : ANNEE, REGION et GENRE
- Faire la jonction entre les deux fichiers avec un « FULL OUTER JOIN »



Méthodologie :

Modélisation avec DBT :

(Marts)

- Calcul du total d'étudiants en formation OpenClassroom et classique
- Calcul des pourcentages d'étudiant par année, région et genre
- Grouper les données par année, région et genre
- Les ordonner dans le même ordre



Méthodologie :

Automatisation :

- Création d'un environnement de production
- Création d'un « job » rattaché à ce nouvel environnement
- Lancement du job pour récupérer le pipeline automatisé (et commenté)

Traitement des données préparées avec un logiciel de visualisation de données :

- Ici PowerBI



RGPD :

Réglementation générale sur la protection des données :


- Utilisation des données uniquement nécessaires à notre analyse
- Conservation uniquement USER_ID anonymisé
- Conservation limité le temps du projet
- Stockage sur un environnement sécurisé (Snowflake et DBT Cloud)



Analyse OpenClassroom :


Répartition géographique des étudiants

Evolution du nombre d'élève parcours data




Répartition des genres par région 2022

SEXE ● F ● M ● unknown



Répartition des genres par région 2025

SEXE ● F ● M ● unknown




- Chute du nombre d'inscrits depuis 2022 avant regain en 2024
- Peu de changement dans la répartition géographique
- Population d'élèves majoritairement masculins dans l'ensemble des régions




Analyse parcours classique:


Somme de Nombre d'étudiant par ANNEE



Répartition des genres par région




Répartition géographique des étudiants



- Chute douce du nombre d'inscrits sur la période
- Population d'élève majoritairement féminine dans l'ensemble des régions



Comparaison (2022-2023) :




OpenClassroom

Répartition géographique des étudiants



Classique

Répartition géographique des étudiants



- Davantage de femmes pour les études « Classique »
- Répartition des étudiants similaire
- Baisse de l'attrait pour les analyses de données dès 2022 pour les deux secteurs



Conclusion :

- **Après une explosion du métier de DATA ANALYST entre 2015-2021, le marché s'est stabilisé, à cela s'ajoute l'émergence de l'IA Générative dès 2022**
 - A partir de 2024 on redécouvre la fiabilité du Data Analyste, le métier évolue
- **En formation classique « initial » statistiquement, les femmes réussissent mieux dans les études longues**
 - Les profils « adultes » constituent un monde différent, l'origine professionnelle, la charge mentale des femmes établies en couple, et l'appétence pour le risque supérieur chez les hommes sont des freins à une reconversion
- **La répartition géographique est très liée à plusieurs facteurs :**
 - La démocratisation du haut débit permet d'étudier plus facilement à distance
 - La répartition du nombre d'élèves suit le nombre d'habitants de chaque région
 - Le bassin d'emplois de chaque région

