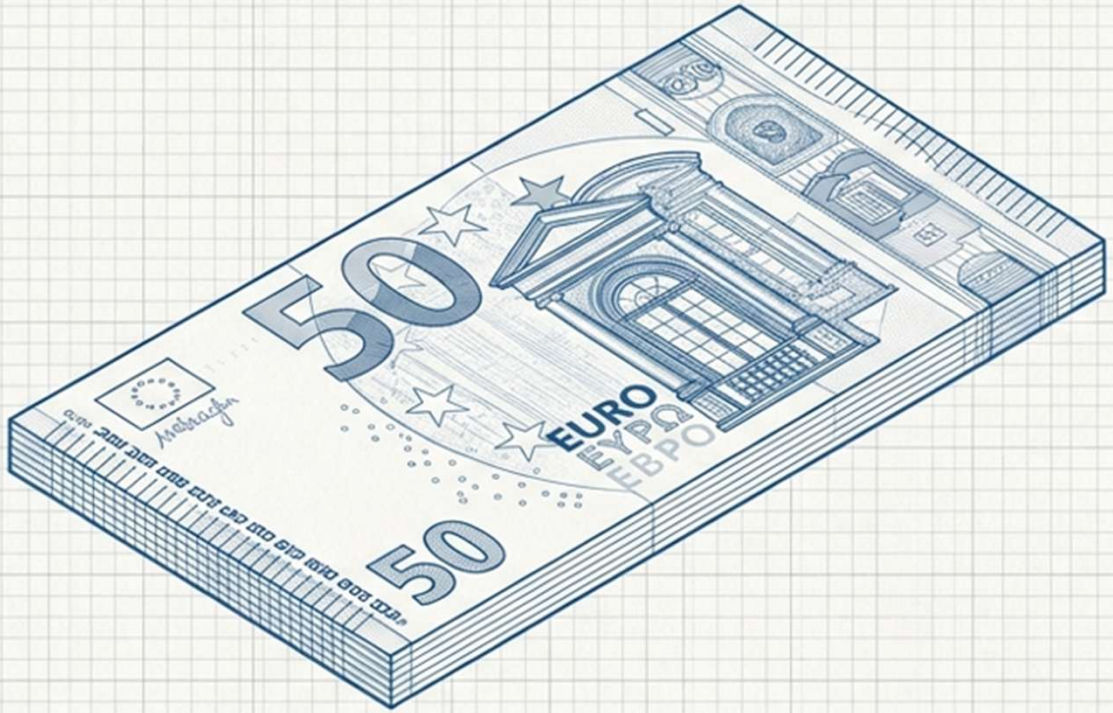
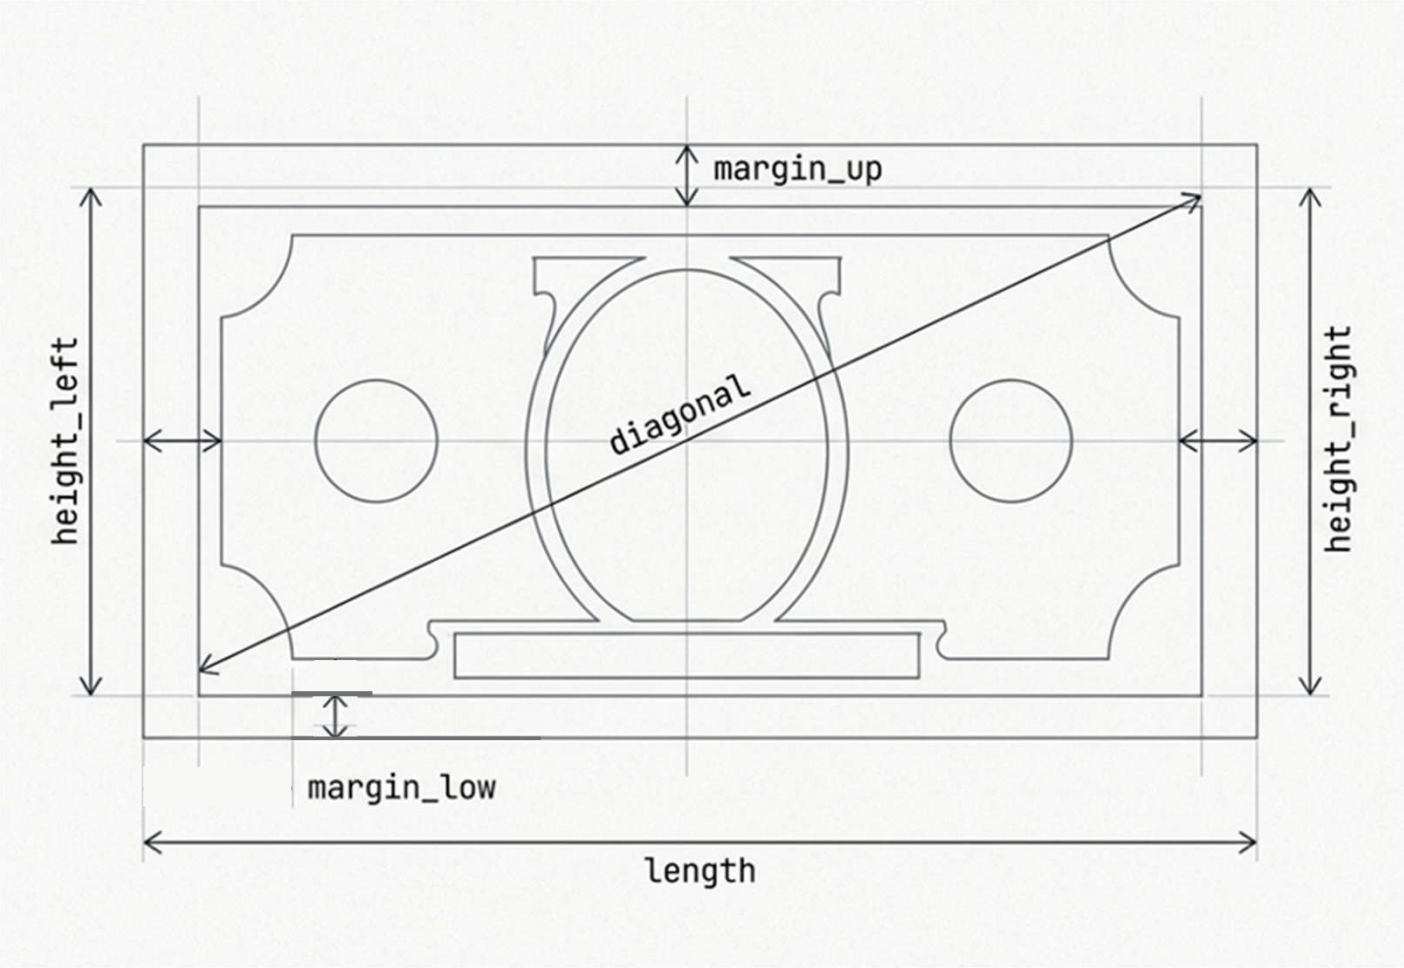
Détection automatisée de faux billets : Analyse, Modalisation et Résolution



Pour
l'ONCFM

Paramètres de l’étude



1500

Billets au total mesurés au millimètre près

1000

Authentiques

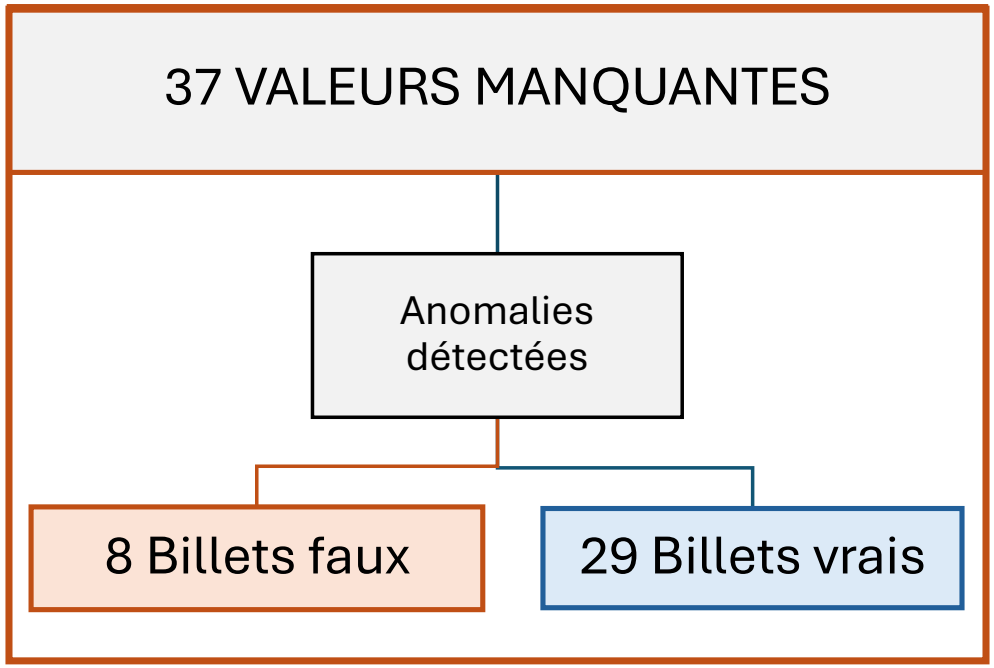
500

Contrefaçons

La base de données fournit 6 dimensions géométriques précises pour entrainer le système de détection

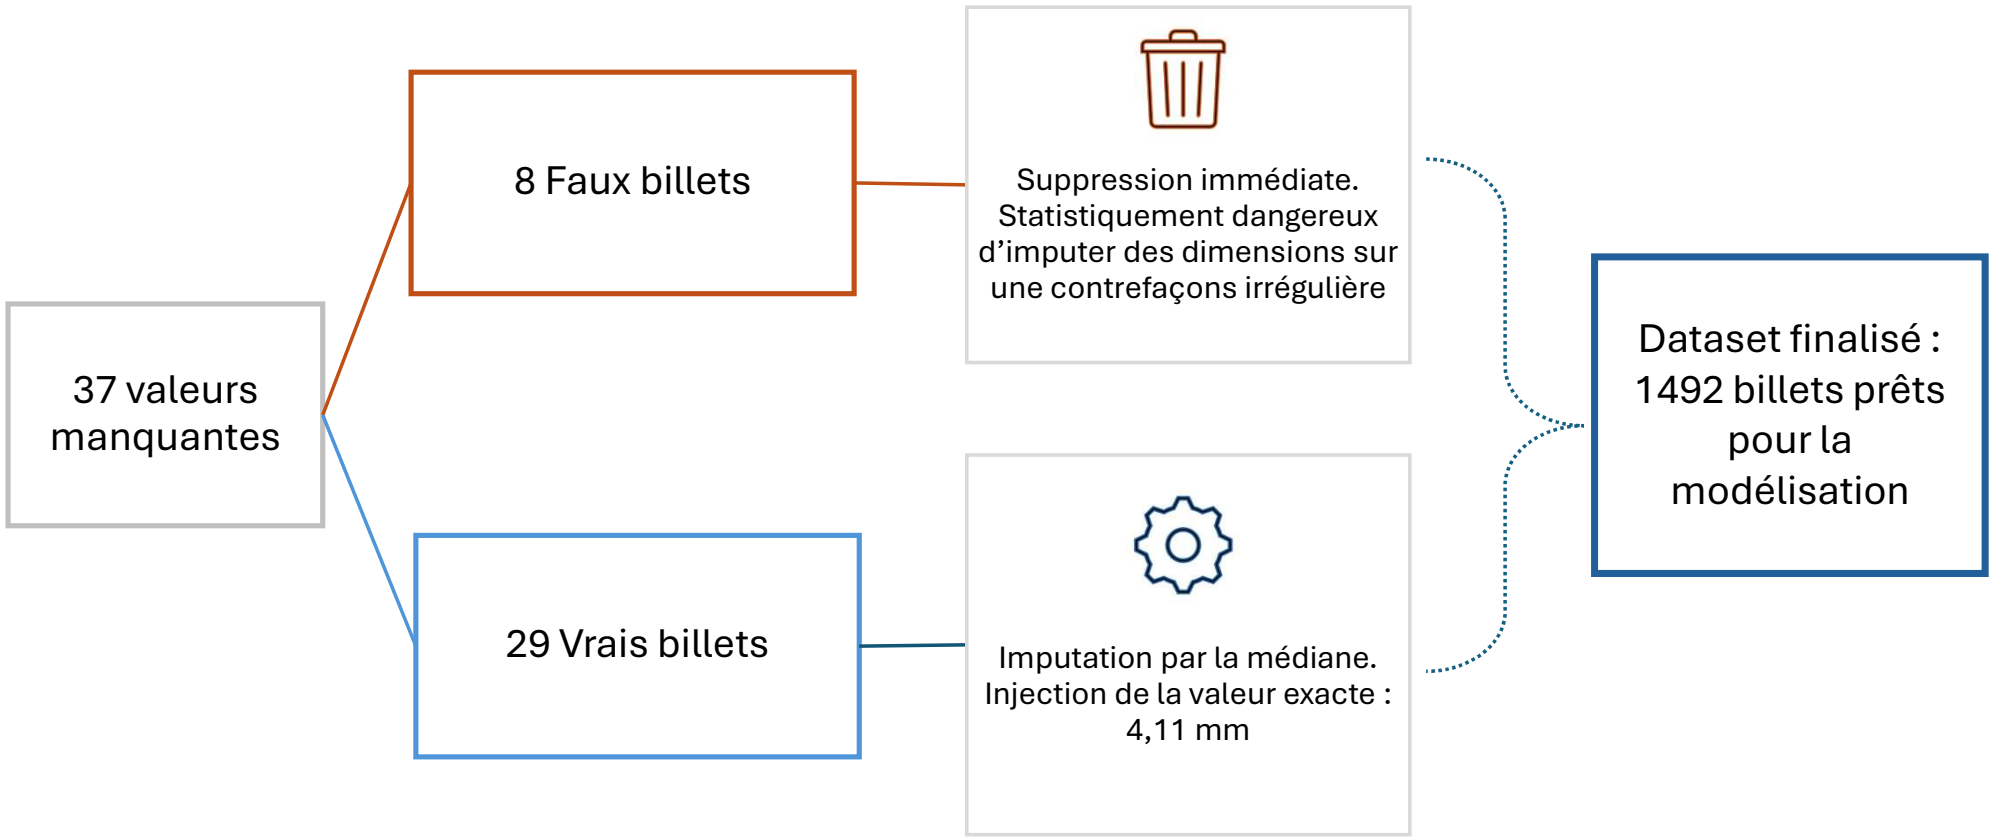
Le cas margin_low

Jeu de données	
Variables	Valeurs manquantes
is_genuine	0
diagonal	0
height_left	0
height_right	0
margin_up	0
margin_low	37 ⚠
length	0



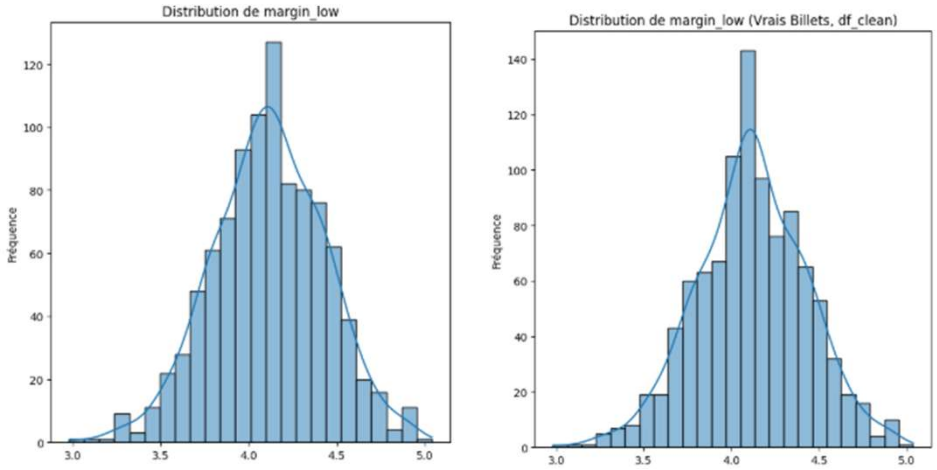
Une anomalie isolée mais critique nécessite une stratégie de traitement asymétrique pour ne pas biaiser l'apprentissage

Stratégie de nettoyage

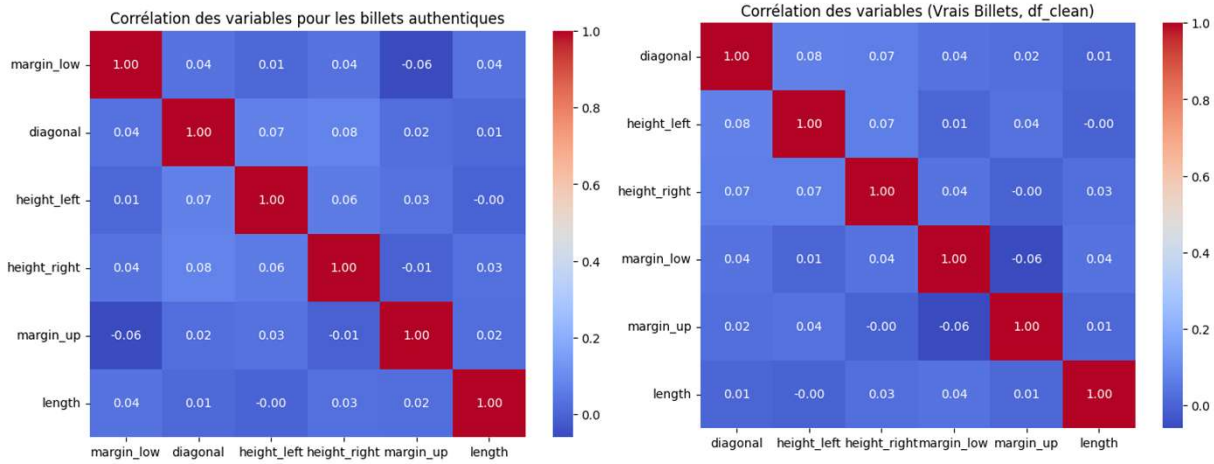


Stratégie de nettoyage

Distribution

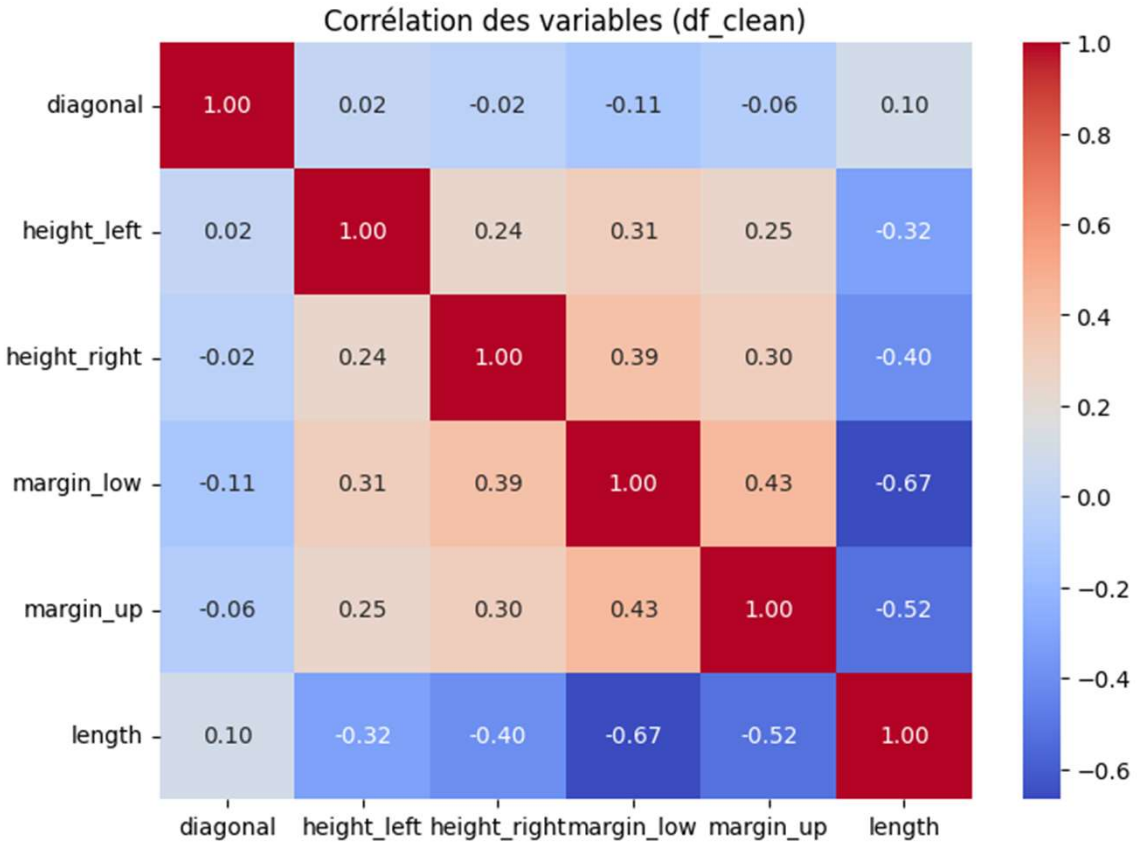


Corrélation



L'injection de la médiane n'altère ni la distribution naturelle ni les relations géométriques sous-jacentes du billet

Visualisation de la base de données



La matrice de corrélation de notre base de données après nettoyage montre des schémas de corrélation qui reflètent maintenant les caractéristiques combinées des vrais et faux billets

Les dimensions du billet sont étroitement liées : la forte corrélation négative entre la longueur et les marges suggère que les anomalies de format constituent un indicateur majeur de contrefaçon

Recommandations EMV



Modèle 1 : K-Means

Non-supervisé.
Découverte naturelle de groupes géométriques.



Modèle 2 : Régression Logistique

Supervisé linéaire.
Transparence absolue et lisibilité des coefficients.



Modèle 3 : K-Nearest Neighbors

Supervisé par distance.
Flexibilité mathématique non-linéaire.

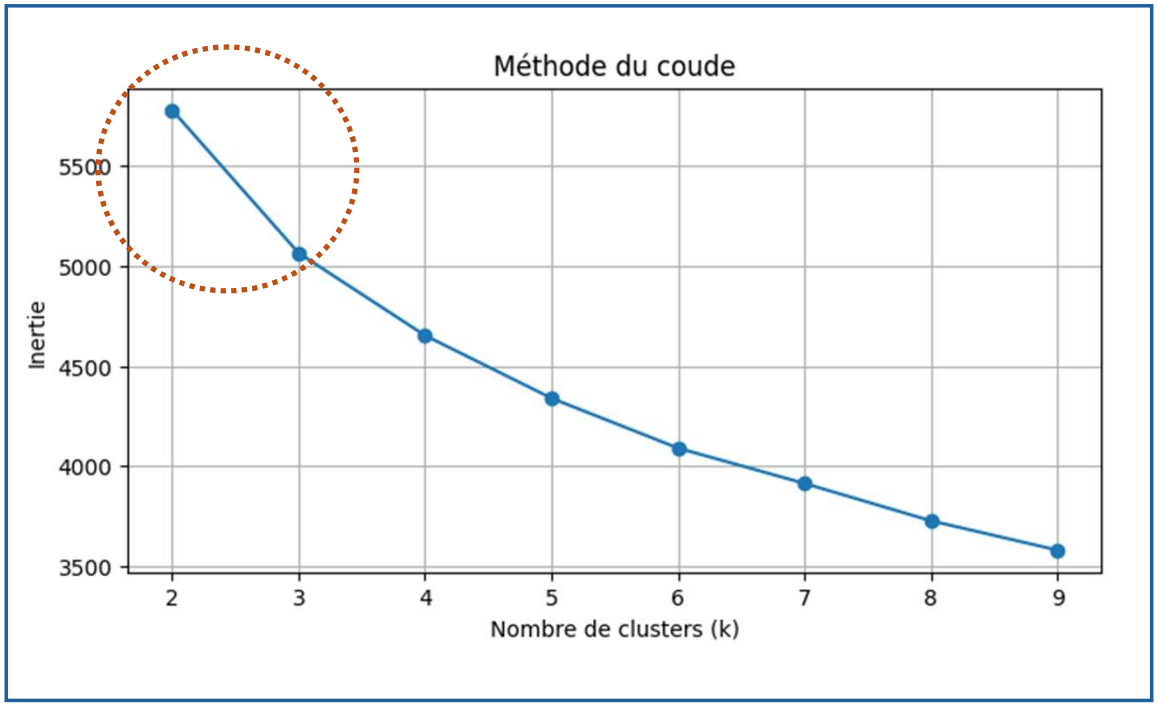


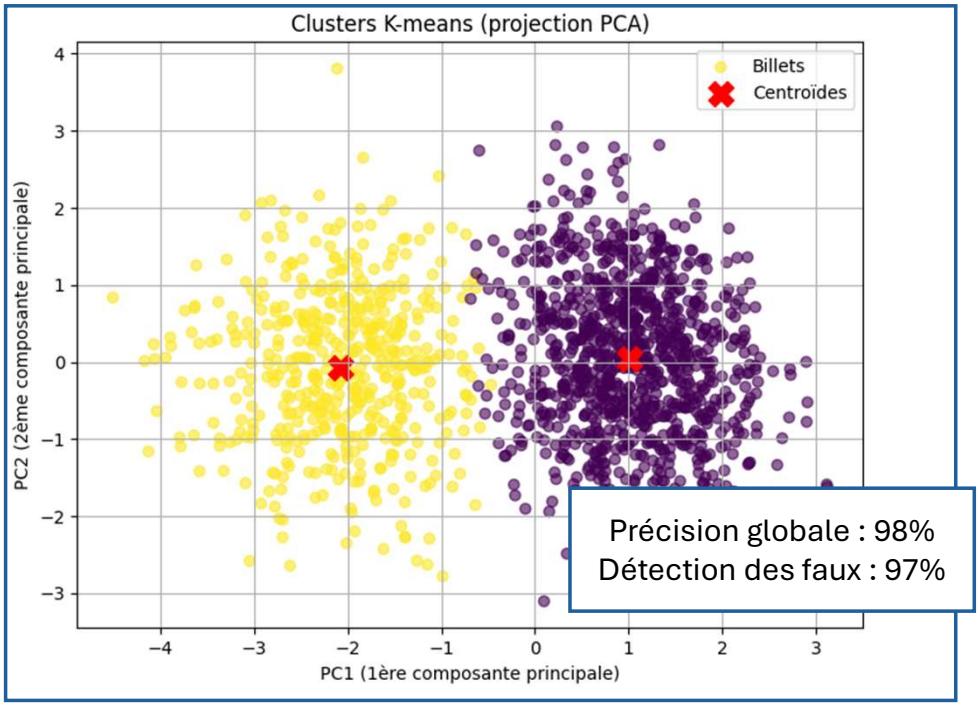
Modèle 4 : Random Forest

Supervisé d'ensemble.
Robustesse et hiérarchisation pure des variables.

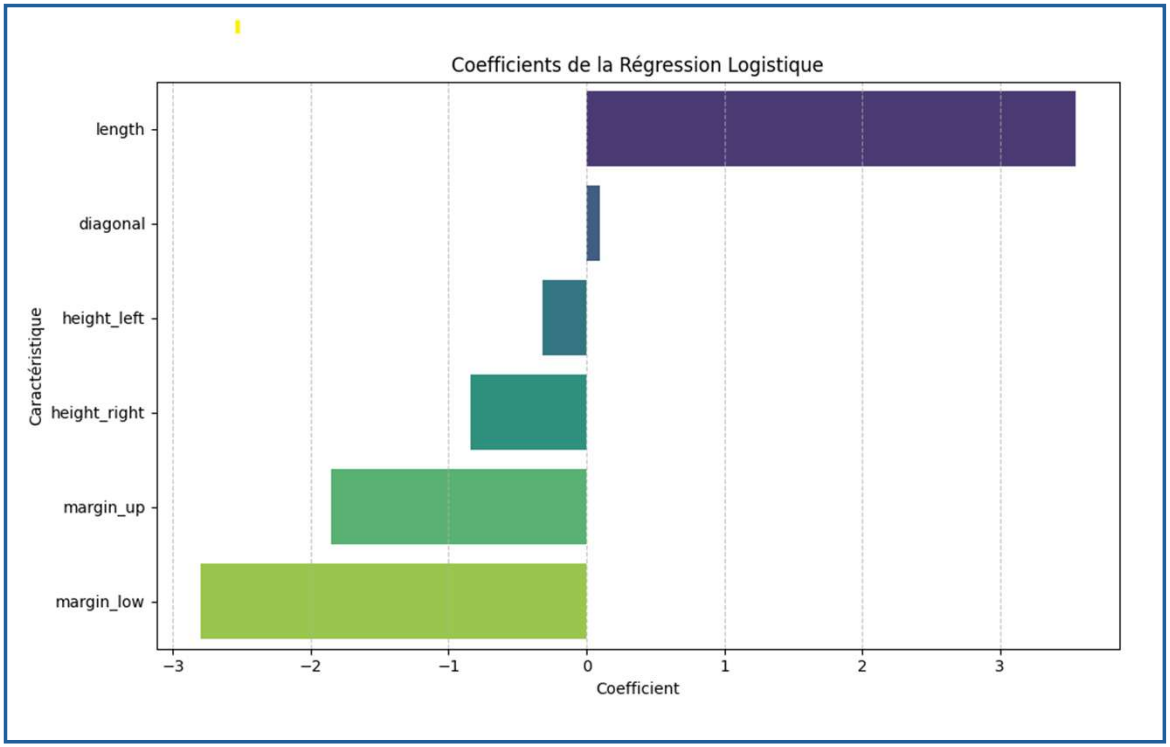
Pré-requis géométrique : Standardisation Z-score appliquée à tous les modèles sensibles à l'échelle (K-Means, LogReg, KNN) pour uniformiser les millimètres

1 : K-Means (regroupement naturel)





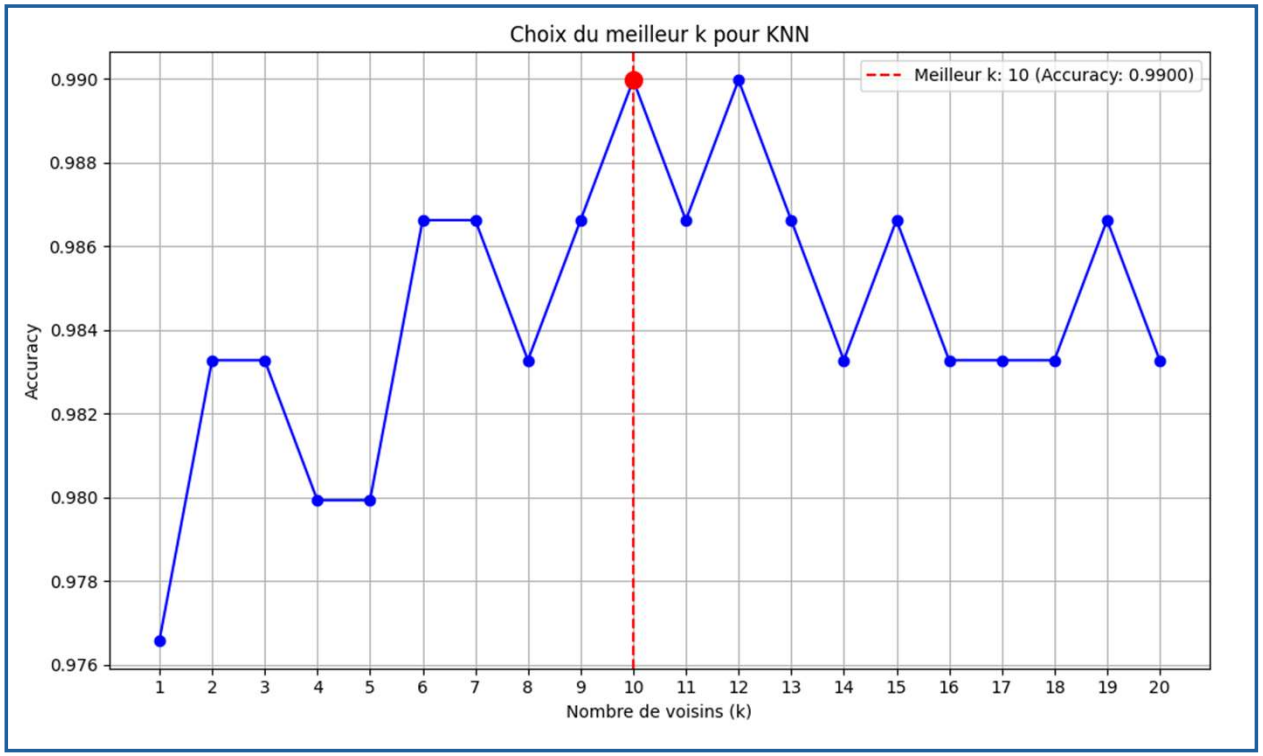
2 : Régression Logistique (approche linéaire)



Le modèle crée une équation mathématique transparente. Un billet long augmente la probabilité de validation. Des marges anormalement larges font chuter cette probabilité

Précision globale : 99%

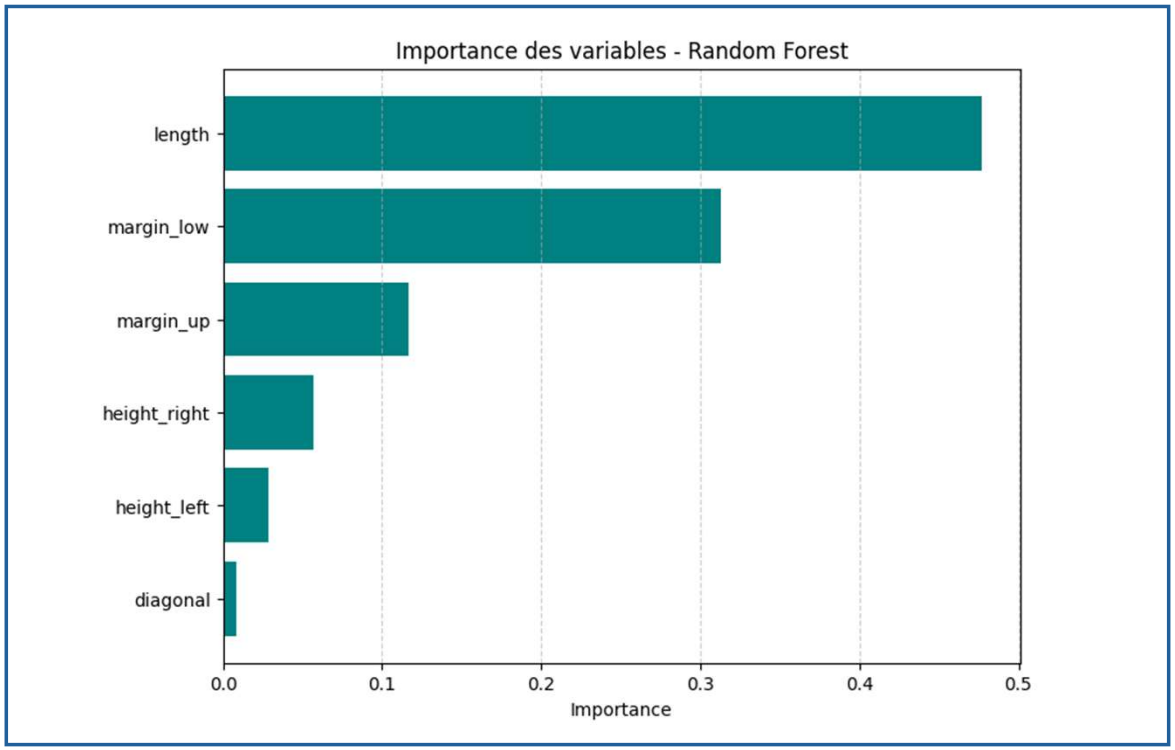
3 : K-Nearest Neighbors (La proximité)



L'algorithme juge l'authenticité d'un billet en cartographiant ses plus proches voisins géométriques. L'équilibre mathématique parfait est atteint en consultant exactement 10 voisins de références

Précision globale : 99%
AUC : 0,988

4 : Random Forest



En générant des centaines d'arbres de décisions, le modèle confirme la supériorité de deux dimensions physiques pour déceler une contrefaçon, sans nécessiter de standardisation préalable

Précision globale : 99%

Bilan des algorithmes

Modèle	Précision globale	Faux positifs	Faux négatifs	Explicabilité
K-Means	98%	13	10	Faible (Boite noire)
Régression Logistique	99%	2	1	Excellente (Coefficient)
KNN	99%	3	1	Moyenne (Dépend de K)
Random Forest	99%	3	1	Bonne (solution lourde)

Les trois modèles supervisés atteignent la quasi-perfection algorithmique (99%), mais se départagent sur leurs erreurs et leur lisibilité institutionnelle

Modèle sélectionné

Régression logistique

Performance maximale

Atteint le score de 99% de prédiction exact et le taux critique le plus bas avec seulement 2 faux positifs

Audibilité

Une équation linéaire compréhensible. Contrairement aux boites noires, chaque décision algorithmique peut-être justifiée réglementairement

Légèreté opérationnelle

Un modèle mathématique pur, assurant une exécution ultrarapide en production sur les trieuses bancaires